

PROGETTO DI CORSO: MACHINE LEARNING

GISOLFI DANILO VINCENZO MAIELLARO

Sommario

1.	Introduzione	3
2.	Fonte dei dati	4
3.	Formato dei dati	5
4.	Data cleaning	7
5.	Data training	8
5.1	Linear Regression	8
5.2	Ridge Regression	8
5.3	Lasso Regression	8
5.4	ElasticNet	8
5.5	Bayesian Ridge Regression	8
5.6	Codice	9
6.	Risultati	11
6.1	Interfaccia Grafica	11
6.2	Differenze tra i modelli	12
6.3	Alcuni esempi	14
7	Conclusioni	16

1. Introduzione

L'obiettivo del progetto è mettere in correlazione i dati riguardanti le polveri sottili PM2.5 e il Prodotto Interno Lordo (GPD) delle singole nazioni nel mondo.

Le polveri sottili PM2.5 sono particelle con un diametro inferiore a 2.5 micron (µm) e le principali fonti di emissione riguardano i veicoli a motore, le centrali elettriche e i processi industriali.

Secondo le raccomandazioni dell'OMS (Organizzazione Mondiale della Sanità) la media giornaliera non dovrebbe superare i $10 \mu g/m^3$, mentre la media annua i $25 \mu g/m^3$. Si stima inoltre che ogni anno nel mondo 8 milioni di decessi siano attribuibili all'esposizione ad inquinanti emessi nelle attività quotidiane alimentate dall'utilizzo di combustibili come legna, carbone e residui organici.

La situazione in Italia non è delle migliori, anche a causa della conformazione geografica della nostra penisola siamo uno dei paesi europei che subiscono più conseguenze a causa dell'inquinamento, infatti città come Torino, Milano e Roma hanno toccato il valore annuo di quasi $200~\mu g/m^3$ provocando oltre 140~morti al giorno.

La correlazione tra il PIL di un Paese e le concentrazioni di PM2.5 offre un punto di osservazione per comprendere come il progresso economico impatti direttamente sulla qualità dell'aria e, di conseguenza, sulla salute umana e ambientale. Da alcuni anni questi valori sono in calo ma quand'è che si arresteranno le concentrazioni di PM2.5? Questo è quello che si vuole ottenere da questo progetto.

ET-EcoTrend Pag. 3 | 16

2. Fonte dei dati

I dataset sono stati presi da <u>kaggle</u> e riguardano i dati di ogni nazione del mondo dal 2010 al 2017. Le fonti specifiche sono le seguenti:

- PM2.5: https://www.kaggle.com/datasets/kweinmeister/pm25-global-air-pollution-20102017
- GDP: https://www.kaggle.com/datasets/nicklitwinow/gdp-by-country

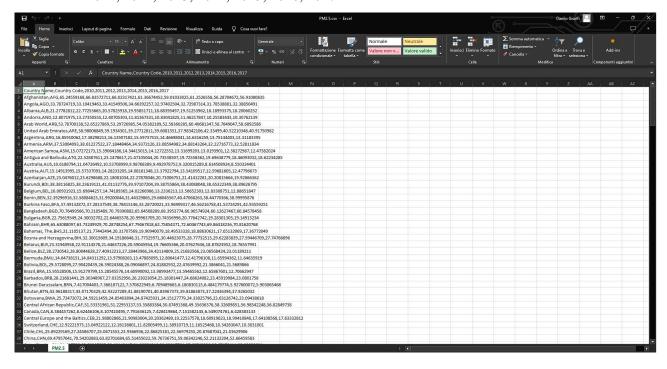
Come anticipato poc'anzi questi dataset forniscono informazioni sull'inquinamento atmosferico (PM2.5) e sul Prodotto Interno Lordo (GDP) utili per modellare il progetto preso in considerazione.

ET-EcoTrend Pag. 4 | 16

3. Formato dei dati

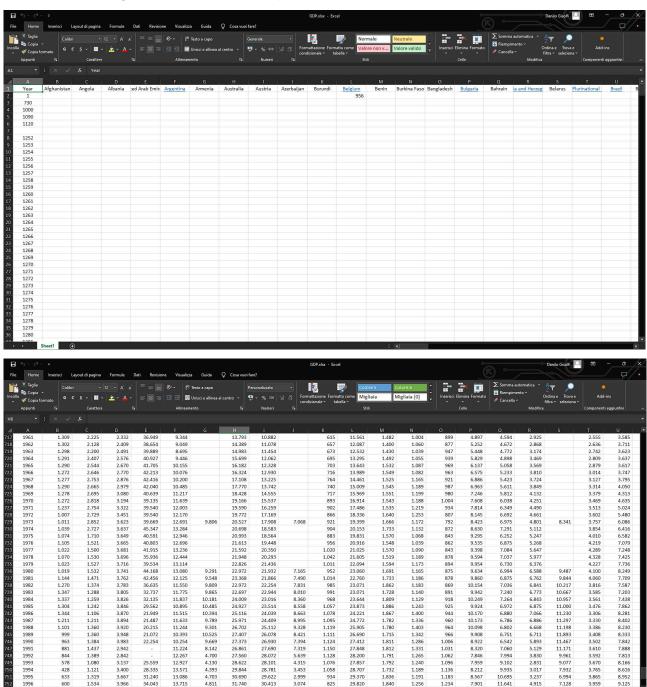
È stato fatto uso di due diversi formati per rappresentare i dati:

- PM2.5 (.csv): per i dati sulle polveri sottili. È stato usato questo formato, basato su testo separato da virgole perché è leggero e con possibilità di essere letto o scritto facilmente grazie alla sua la struttura chiara di colonne e righe.
 - Questo dataset è composto dalle seguenti colonne: Country Name, Country Code, 2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017



ET-EcoTrend Pag. 5 | 16

- GDP (.xlsx e successivamente .csv): per i dati riguardanti il Prodotto Interno Lordo (GDP). È stato utilizzato inizialmente il formato .xlsx, (solitamente associato ai fogli di calcolo di Excel) che è noto per gestire dati più complessi. Tuttavia, per semplificare la gestione e l'analisi dei dati è stato successivamente convertito in formato .csv.
 - Questo dataset è composto dalle seguenti colonne: Year, Afghanistan, Angola, Albania,
 United Arab Emirates, Argentina, Armenia, Australia, Austria, Azerbaijan, Burundi,
 Belgium, Benin, ... (e così via)



ET-EcoTrend Pag. 6 | 16

4. Data cleaning

Inizialmente entrambi i dataset sono stati aperti e letti:

```
dataset_inquinamento = pd.read_csv("PM2.5.csv")
dataset_gdp = pd.read_excel("GDP.xlsx")
```

Successivamente dai dataset sono state rimosse tutte le righe duplicate, tutti i valori nulli rispettivamente attraverso le funzioni .drop duplicates() e .dropna():

```
dataset_inquinamento = dataset_inquinamento.drop_duplicates()
dataset_inquinamento = dataset_inquinamento.dropna()
```

```
dataset_gdp = dataset_gdp.drop_duplicates()
dataset_gdp = dataset_gdp.dropna()
```

Siccome i dati riguardanti le polveri sottili vanno dal 2010 al 2017, era superfluo mantenere altri dati che non potevano essere messi a confronto, quindi dal dataset GDP sono stati rimossi tutti i dati fino al 2009 compreso:

```
dataset_gdp['Year'] = pd.to_datetime(dataset_gdp['Year'], format='%Y', errors='coerce')

dataset_gdp = dataset_gdp[dataset_gdp['Year'].dt.year >= 2010]

dataset_gdp['Year'] = dataset_gdp['Year'].astype(str)

dataset_gdp['Year'] = dataset_gdp['Year'].str.replace('-01-01', '')
```

Infine i nuovi dataset sono stati correttamente salvati:

```
dataset_inquinamento.to_csv("PM2.5_filtered.csv", index=False)
dataset_gdp.to_csv("GDP_filtered.csv", index=False)
```

ET-EcoTrend Pag. 7 | 16

5. Data training

I dataset sono stati addestrati attraverso 5 modelli. Segue una breve descrizione di ciascuno di essi.

5.1 Linear Regression

La regressione lineare è come tracciare una linea attraverso i dati, è come immaginare di avere dei punti su un grafico e di voler trovare una linea retta che si avvicini il più possibile a quei punti. La regressione lineare fa proprio questo, cerca di trovare la linea che rappresenta meglio la relazione tra le variabili.

5.2 Ridge Regression

La Ridge Regression è una versione della regressione lineare che aiuta a prevenire l'overfitting. Questo fenomeno si verifica quando il modello "impara" non solo i modelli generali nei dati, ma anche il rumore specifico del set di addestramento. La Ridge Regression aggiunge una penalità ai coefficienti evitando che essi diventino troppo grandi, in questo modo il modello diventa più stabile e meno sensibile a piccole variazioni nei dati di addestramento.

5.3 Lasso Regression

Lasso Regression è simile a Ridge, ma con una differenza, anch'esso aggiunge una penalità ai coefficienti in modo che alcuni di essi possano diventare zero ma può anche selezionare automaticamente le variabili più importanti per il modello, riducendo il numero di fattori presi in considerazione. Questo può rendere il modello più semplice e interpretabile.

5.4 ElasticNet

ElasticNet è una combinazione di Ridge e Lasso Regression. Quindi, include sia la penalità che gestisce l'overfitting (come Ridge) sia la capacità di ridurre il numero di variabili a zero (come Lasso). Questo offre una flessibilità maggiore nella gestione di diversi tipi di dati.

5.5 Bayesian Ridge Regression

Bayesian Ridge Regression è basato sulla teoria bayesiana e cerca una distribuzione di probabilità su tutti i possibili set di pesi del modello. Questo significa che tiene conto dell'incertezza nei dati e fornisce una stima della distribuzione di probabilità sui parametri del modello. È utile quando si ha poca sicurezza sui dati e si vuole considerare la possibilità di molteplici set di pesi.

ET-EcoTrend Pag. 8 | 16

5.6 Codice per l'addestramento

```
anni = np.array([2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017])
def addestra_modelli(dataset_inquinamento, dataset_gdp, model_type):
   modelli_per_paese_inquinamento = {}
   modelli_per_paese_gdp = {}
   for paese in dataset_inquinamento['Country Name'].unique():
        dati_paese = dataset_inquinamento.loc[dataset_inquinamento['Country Name'] == paese,
anni.astype(str)]
        if model_type == 'linear_regression':
            model = LinearRegression()
        elif model_type == 'ridge':
           model = Ridge()
        elif model_type == 'lasso':
            model = Lasso()
        elif model_type == 'elastic_net':
            model = ElasticNet()
        elif model_type == 'bayesian_ridge':
           model = BayesianRidge()
            raise ValueError("Tipo di modello non supportato.")
        model.fit(anni.reshape(-1, 1), dati_paese.values.flatten())
        modelli_per_paese_inquinamento[paese] = model
    for paese in dataset_gdp.columns[1:]:
       X_gdp = dataset_gdp['Year'].astype(int).values.reshape(-1, 1)
       y_gdp = dataset_gdp[paese].values
        if model type == 'linear regression':
            model_gdp = LinearRegression()
        elif model type == 'ridge':
            model_gdp = Ridge()
        elif model_type == 'lasso':
            model gdp = Lasso()
        elif model_type == 'elastic_net':
            model_gdp = ElasticNet()
        elif model_type == 'bayesian_ridge':
            model gdp = BayesianRidge()
            raise ValueError("Tipo di modello non supportato.")
        model_gdp.fit(X_gdp, y_gdp)
       modelli_per_paese_gdp[paese] = model_gdp
```

ET-EcoTrend Pag. 9 | 16

return modelli per paese inquinamento, modelli per paese gdp

```
modelli_per_paese_inquinamento_linear_regression, modelli_per_paese_gdp_linear_regression =
    addestra_modelli(dataset_inquinamento.copy(), dataset_gdp.copy(), 'linear_regression')

modelli_per_paese_inquinamento_ridge, modelli_per_paese_gdp_ridge =
    addestra_modelli(dataset_inquinamento.copy(), dataset_gdp.copy(), 'ridge')

modelli_per_paese_inquinamento_lasso, modelli_per_paese_gdp_lasso =
    addestra_modelli(dataset_inquinamento.copy(), dataset_gdp.copy(), 'lasso')

modelli_per_paese_inquinamento_elastic_net, modelli_per_paese_gdp_elastic_net =
    addestra_modelli(dataset_inquinamento.copy(), dataset_gdp.copy(), 'elastic_net')

modelli_per_paese_inquinamento_bayesian_ridge, modelli_per_paese_gdp_bayesian_ridge =
    addestra_modelli(dataset_inquinamento.copy(), dataset_gdp.copy(), 'bayesian_ridge')
```

ET-EcoTrend Pag. 10 | 16

6. Risultati

6.1 Interfaccia Grafica

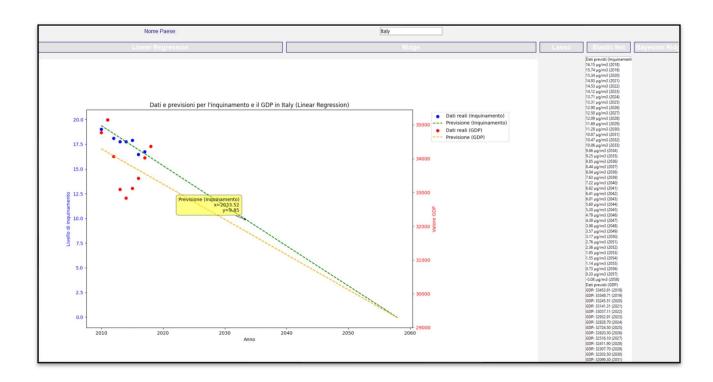
Per visualizzare i risultati è stata realizzata una GUI con un campo che prende in input il nome del Paese del quale si vuole visualizzare la previsione e cinque pulsanti ognuno relativo al modello su cui sono stati addestrati i dataset.



Una volta che l'utente preme su uno di essi verrà mostrato un grafico sul quale è possibile osservare due linee che sono le previsioni dei modelli e una serie di cerchi che riguardano i dati reali estratti dai dataset.

È possibile passare il cursore su ognuna delle linee per visualizzare i singoli dati o in alternativa è presente sulla destra una finestra con i dati suddivisi anno per anno.

È importante notare che non è sicuro le previsioni sull'inquinamento di PM2.5 raggiungano lo zero; quindi, in alternativa, le previsioni si fermeranno all'anno 2100.



ET-EcoTrend Pag. 11 | 16

6.2 Differenze tra i modelli

Come è possibile osservare i modelli producono risultati molto diversi tra loro. Per valutare al meglio le loro prestazioni per ognuno di essi sono state utilizzate due metriche di valutazione:

- Mean Squared Error (MSE), misura la media dei quadrati degli errori tra le previsioni fatte dal modello e i valori che stiamo cercando di prevedere;
- Coefficiente di Determinazione (R²), rappresenta la proporzione di varianza nei dati.

Un MSE più basso indica una migliore precisione nelle previsioni del modello, mentre un R² più alto suggerisce che il modello spiega indica una migliore adattabilità.

Esempio del Paese Italia:

• Linear Regression:

MSE: 0.2609 R²: 0.7680

Ridge Regression:

MSE: 0.2614 R²: 0.7676

• Lasso Regression:

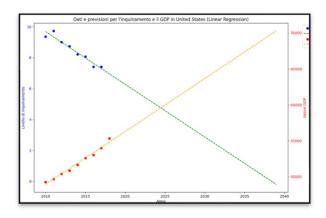
MSE: 0.4514 R²: 0.5986 ElasticNet: MSE: 0.3393 R²: 0.6983

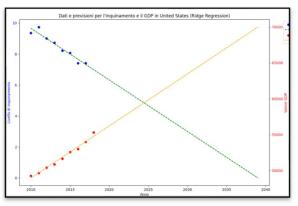
• Bayesian Ridge Regression:

MSE: 0.2625 R²: 0.7666

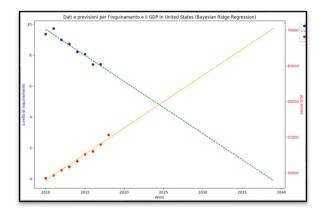
Il modello migliore sembra essere Linear Regression.

Invece nell'esempio che segue è possibile osservare graficamente le differenze dei vari modelli ed è stato inserito 'United States':

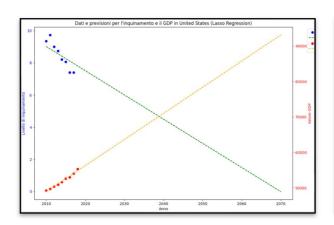


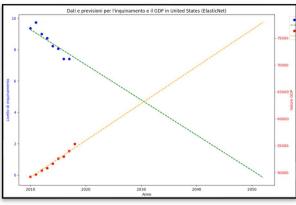


ET-EcoTrend Pag. 12 | 16



Lasso ed Elastic Net sono i modelli che sembrano fare previsioni più lunghe, raggiungendo lo zero più tardi rispetto agli altri modelli (in particolar modo Lasso).



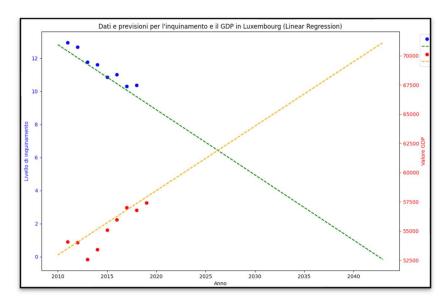


ET-EcoTrend Pag. 13 | 16

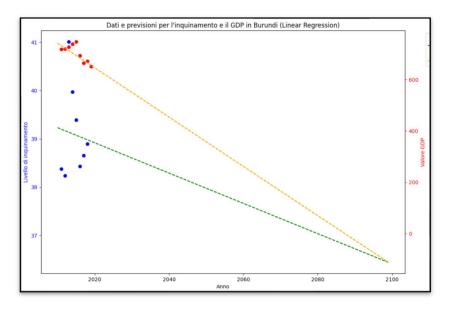
6.3 Alcuni esempi

Di seguito verranno mostrati alcuni esempi:

• Paese più ricco (Lussemburgo):

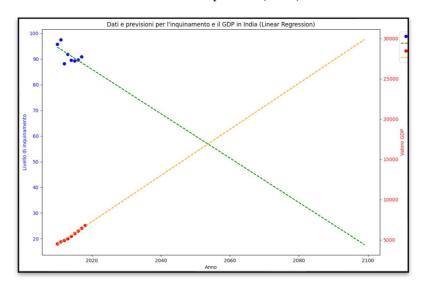


• Paese più povero (Burundi):

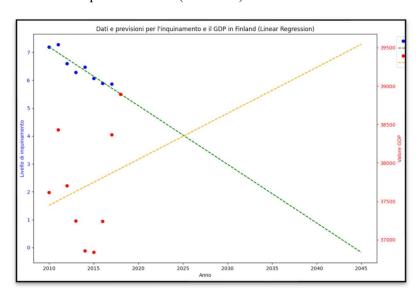


ET-EcoTrend Pag. 14 | 16

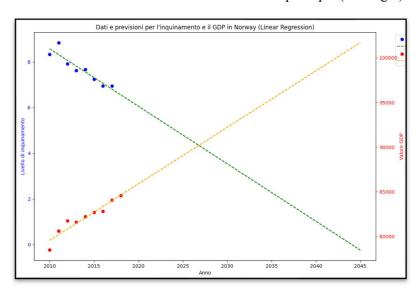
• Paese con tasso di crescita più alto (India):



• Paese più sostenibile (Finlandia):



• Paese con una distribuzione del reddito più equa (Norvegia):



ET-EcoTrend Pag. 15 | 16

7. Conclusioni

La correlazione tra il Prodotto Interno Lordo (GDP) di un Paese e le concentrazioni di PM2.5 offre spunti interessanti sulla relazione tra lo sviluppo economico e la qualità dell'aria.

Alcune riflessioni che possono essere fatte sono che c'è una grande correlazione negativa soprattutto nei paesi in via di sviluppo, suggerendo che in questi contesti si verificano livelli più elevati di inquinamento atmosferico probabilmente associati a:

- una industrializzazione intensa e rapida;
- una mancanza di normative ambientali rigorose consentendo un maggiore rilascio di sostanze inquinanti nell'aria;
- un uso intensivo di fonti energetiche non pulite come il carbone.

Elevati livelli di inquinamento atmosferico oltre ad avere implicazioni sulla salute, impattano negativamente sulla qualità dell'ambiente, compromettendo la biodiversità e influenzando la qualità complessiva degli ecosistemi.

Di contro i Paesi più ricchi potrebbero tendere ad azzerare prima le emissioni di polveri sottili per diverse ragioni:

- maggiori risorse finanziarie disponibili per la ricerca e lo sviluppo di tecnologie migliori e più pulite;
- regolamentazioni ambientali più rigide e controllate che limitano le emissioni industriali e incentivano pratiche più sostenibili;
- consapevolezza ambientale verso la sostenibilità;
- diversificazione dell'energia riducendo la dipendenza da combustibili fossili.

ET-EcoTrend Pag. 16 | 16